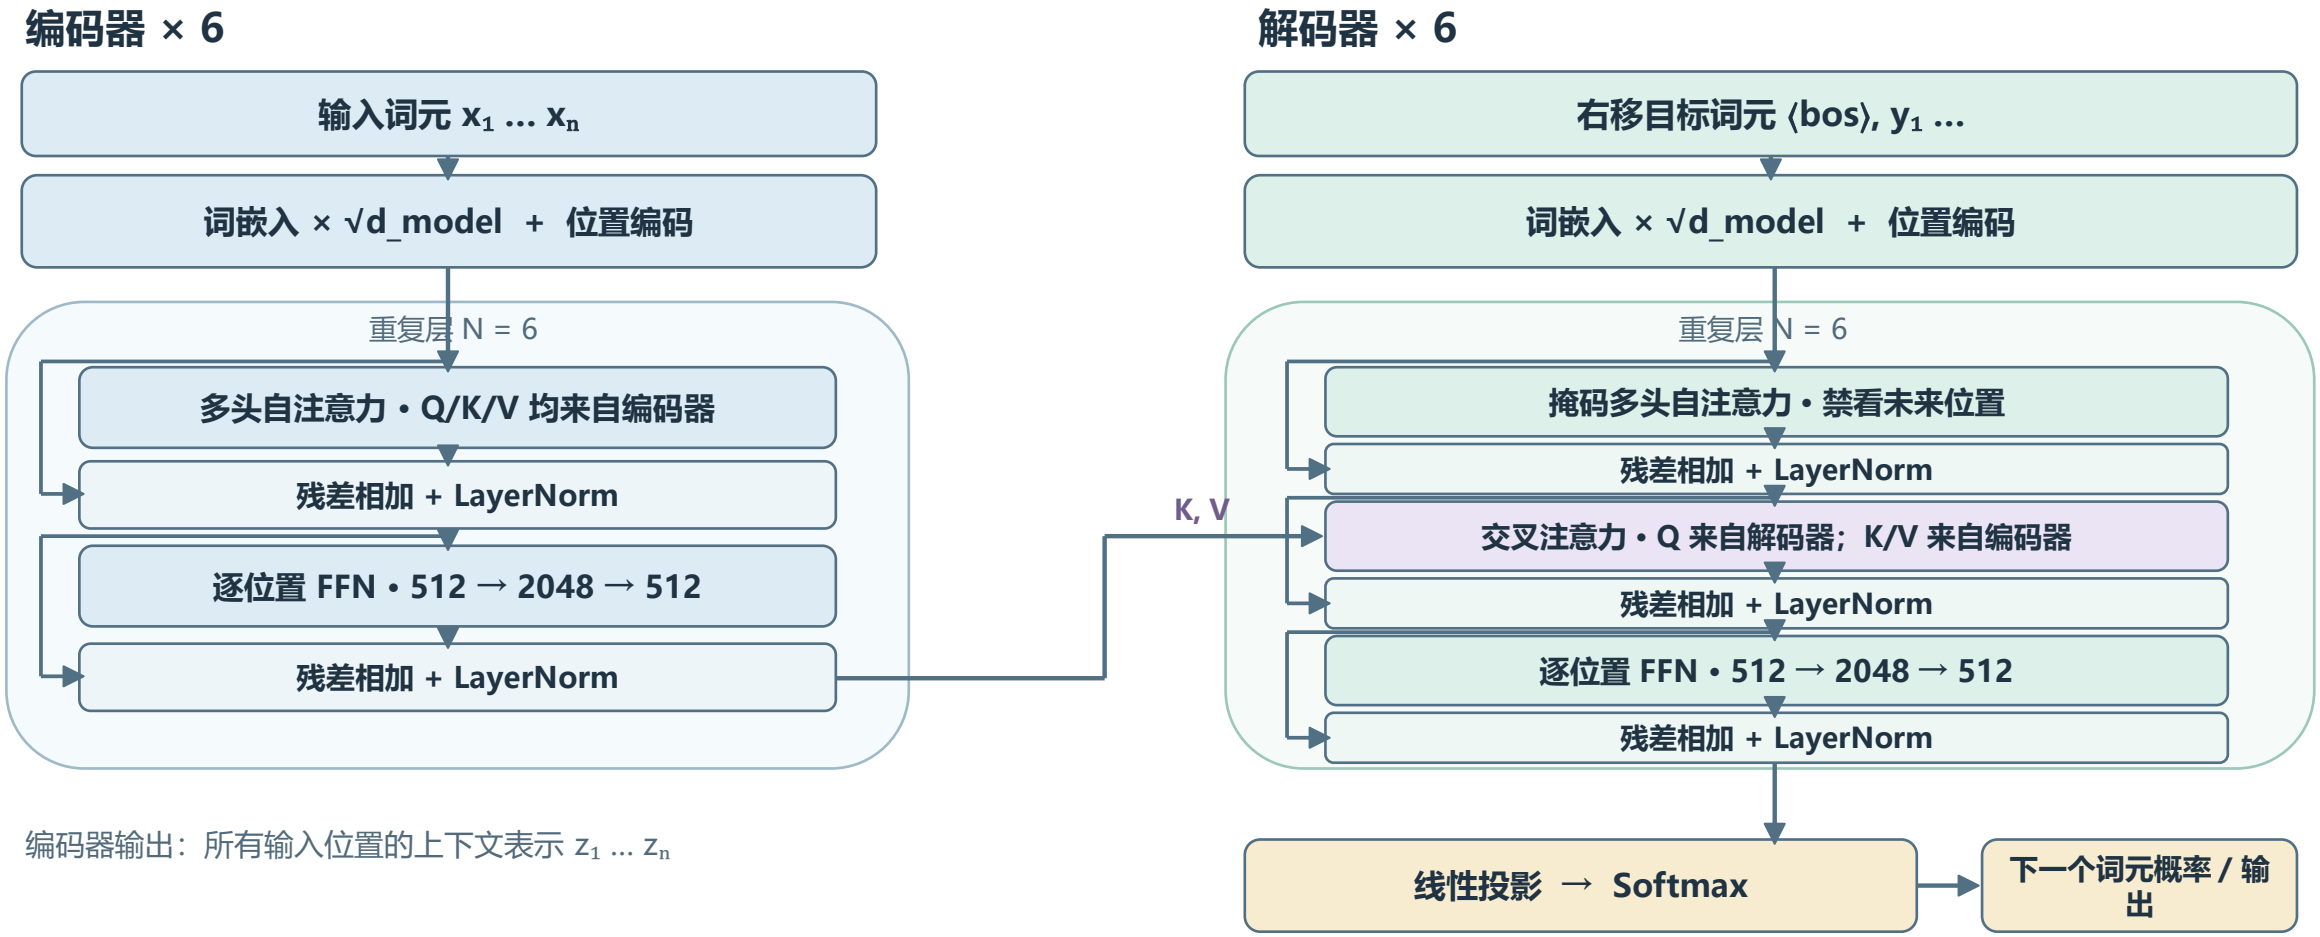
Transformer 原始架构 | 编码器、解码器与信息流

Vaswani et al. (2017) base model · 箭头表示张量依赖；旁路表示残差连接



编码器输出：所有输入位置的上下文表示 $z_1 \dots z_n$

推理时，已生成词元回馈到右移输入；训练时使用右移目标序列。

原论文为 post-LN；d_model = 512，h = 8，d_ff = 2048。

原论文共享两侧词嵌入与 Softmax 前线性层的词表权重。

来源：Vaswani et al., Attention Is All You Need, Fig. 1, §§3.1–3.5。

Transformer 注意力内部 | 多头并行与因果掩码

原始 base model：h = 8，d_k = d_v = 64；编码器自注意力、解码器掩码自注意力与交叉注意力共用此核心

A 多头注意力

输入 Q、K、V

↓

各头独立线性投影：$Q \to Q_i$，$K \to K_i$，$V \to V_i$

↓

Head 1　Head 2　…　Head 8

↓

拼接 $\text{Concat}(\text{head}_1, \ldots, \text{head}_8)$

↓

输出投影 W^O → d_model = 512

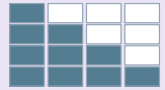
不同头学习不同表示子空间与位置关系；每头执行右侧的缩放点积。

B 缩放点积注意力

相似度 $QK^T / \sqrt{d_k}$

↓

解码器自注意力：未来位置加 $-\infty$



↓

Softmax → 每行归一化的注意力权重

↓

V → 权重 × V → 上下文表示

$$\text{Attention}(Q,K,V) = \text{softmax}((QK^T / \sqrt{d_k}) + M)\,V$$

M = 0（无掩码）；被禁止的位置 M = −∞（解码器自注意力）。

交叉注意力：Q 来自解码器；K、V 来自编码器输出。

位置编码：PE(pos,2i)=sin(pos/10000^(2i/d_model))；PE(pos,2i+1)=cos(同项)　·　$FFN(x)=\text{ReLU}(xW_1+b_1)W_2+b_2$